

# BraInside

## Algorithmes pour la Simplification des Réseaux de Neurones



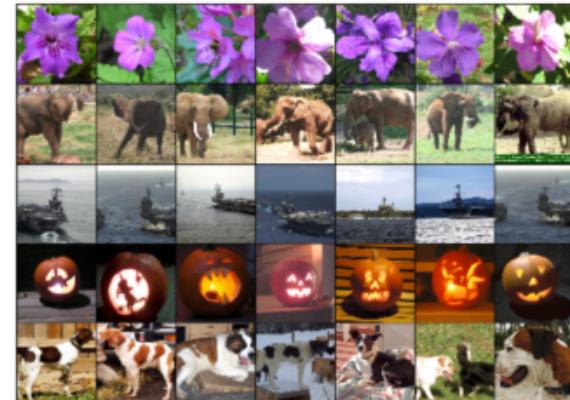
Centre Inria d'Université Côte d'Azur

**Emanuele Natale**

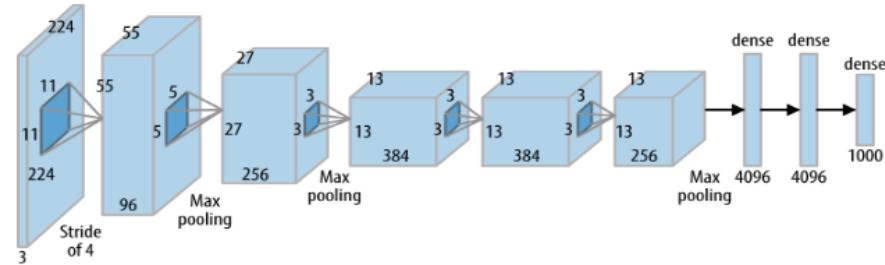
Journée AID-INRIA  
Paris, 12 Juin 2023

# Nécessité de comprimer les réseaux de neurones

Le Deep Learning est devenu populaire en 2012 quand AlexNet a remporté le concours LSVRC 2012.



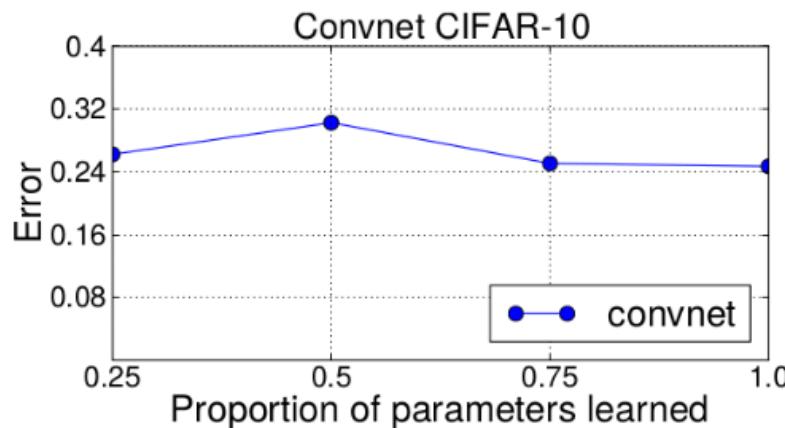
AlexNet a 60 millions de poids (environ 3 Go)



Les architectures de pointe sont “lourdes” pour certains systèmes embarqués



# Comment comprimer les réseaux de neurones ?



Les réseaux de neurones  
ont tendance à être très  
“compressibles”

Différentes familles de  
techniques:

- Techniques de **quantification**
- Techniques d'**algèbre linéaire**
- Techniques d'**élagage**

**BraInside:**

Utiliser les techniques de la théorie des algorithmes pour  
développer de nouvelles techniques d'**élagage**.

# Aperçu du projet BraInside

## Membres

- Emanuele Natale (CR), INRIA UCA
- Laurent Viennot (DR), INRIA Paris
- Arthur Walraven da Cunha (PhD), INRIA UCA
- Paulo Bruno Serafim (Ingénieur de recherche, 6 mois), INRIA UCA
- Damien Rivet (Postdoc, 1 an), INRIA UCA

## Production scientifique

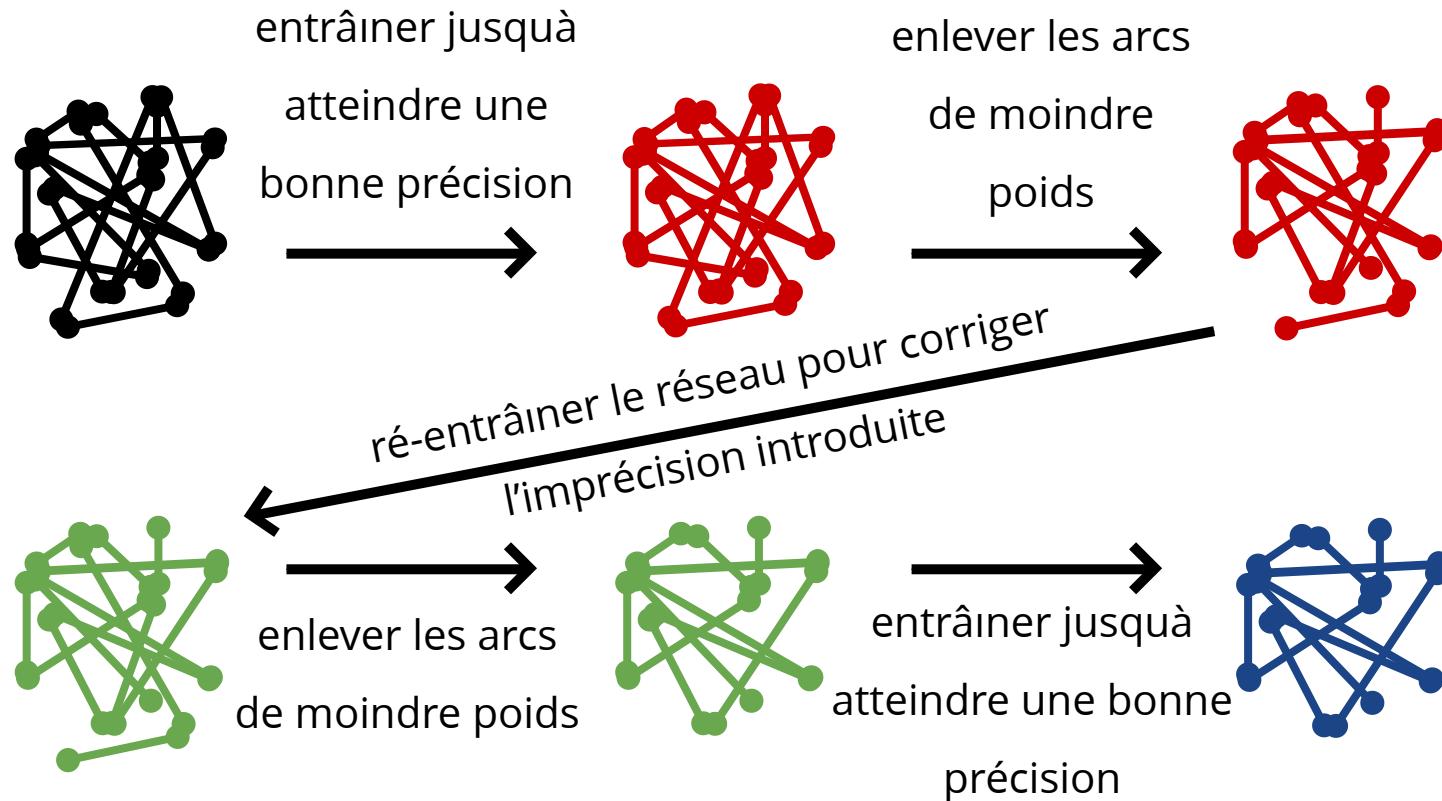
- **4 manuscrits** à publier
- OLA 2023
- **ICLR 2022**
- AAAI 2022

## Autres produits

- **Dépôt de brevet**  
n° FR2210217
- **Logiciel** "Tinynets" en cours de développement

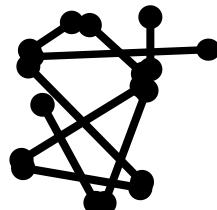
# Élagage itéré par magnitude

Blalock et al. (2020): L'**élagage itéré par magnitude** est toujours une technique de compression de pointe.

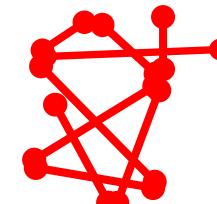


# L'hypothèse du billet de loterie

réseau  
aléatoire  
épars

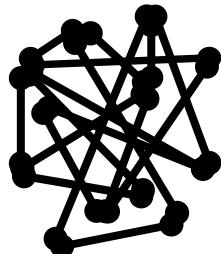


entraînement →

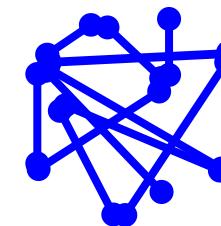


réseau  
épars et  
**inefficace**

grand  
réseau  
aléatoire

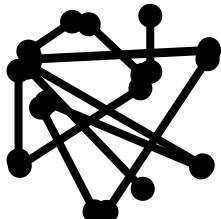


entraîner et élaguer  
à répétition →

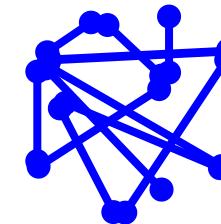


réseau  
épars et  
**efficace**

réseau  
épars  
du billet



réinitialisation  
← entraînement →

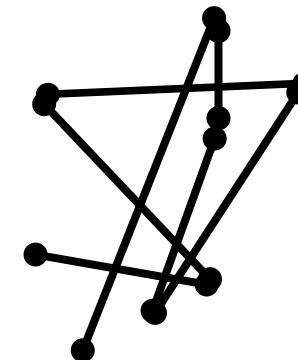
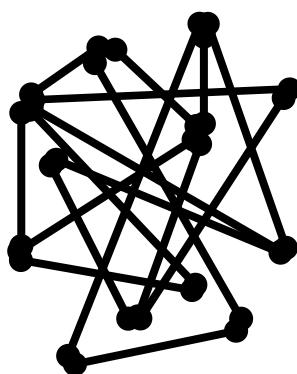


réseau  
épars et  
**efficace**

Frankle & Carbin (ICLR 2019):

Un grand réseau aléatoire contient des sous-réseaux qui atteignent une précision comparable lorsqu'ils sont entraînés.

# L'hypothèse forte du billet de loterie



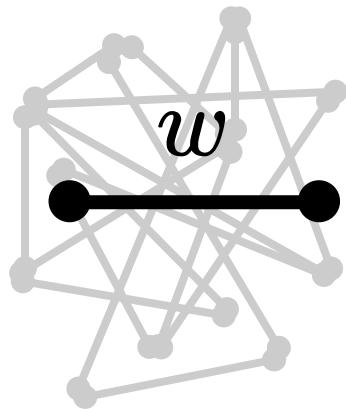
Entraînement par élagage:

Ramanujan et al. (CVPR 2020) trouvent un bon sous-réseau sans changer les poids



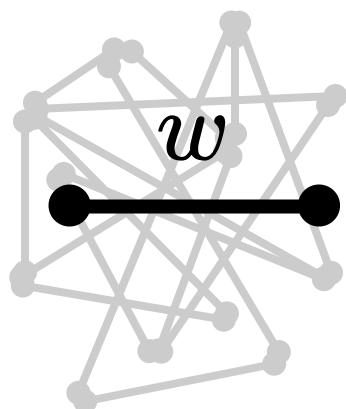
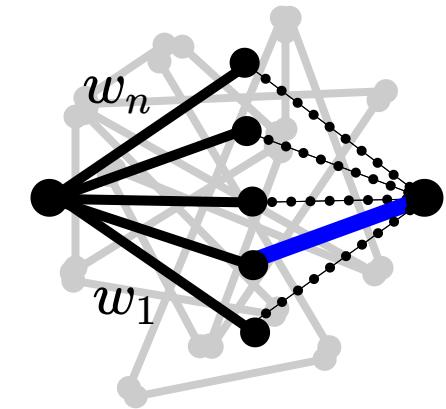
Un réseau avec des poids aléatoires contient des sous-réseaux qui peuvent approximer n'importe quel réseau neurones donné suffisamment plus petit  
(sans entraînement)

# Prouver l'hypothèse forte du billet de loterie



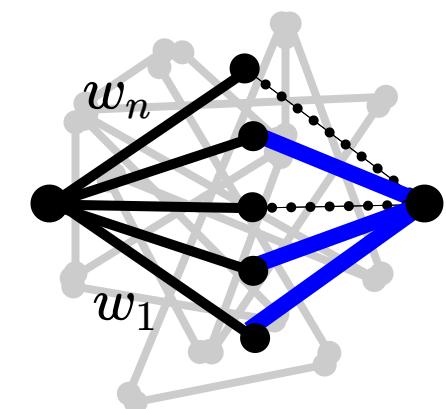
Malach et al. (ICML 2020)

Trouve un poids aléatoire  
proche de  $w$

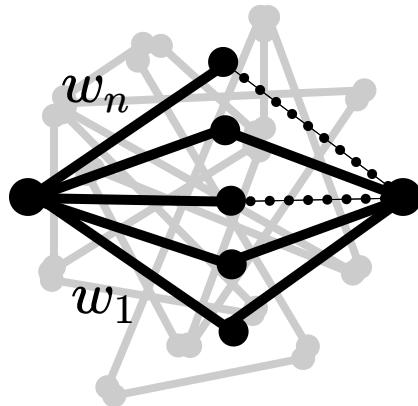


Pensia et al. (NeurIPS 2020)

Trouve une combinaison de  
poids aléatoires proche de  $w$



# La liaison avec le problème de la somme du sous-ensemble aléatoire



Trouver une combinaison de poids aléatoires proche de  $w$ :

$$\sum_{i \in S \subseteq \{1, \dots, n\}} w_i \approx w$$

**PSSA.** Pour quelle variable  $n$  l'énoncé suivant est-il valable ?

Étant donné  $X_1, \dots, X_n$  variables aléatoires indépendantes, avec prob.  $1 - \epsilon$  pour chaque  $z \in [-1, 1]$  il existe  $S \subseteq \{1, \dots, n\}$  tel que

$$|z - \sum_{i \in S} X_i| \leq \epsilon.$$

Connexion profonde avec les programme linéaires aléatoires

[Dyer & Frieze '89,  
Borst et al. '22]

Lueker '98:  
 $n = O(\log \frac{1}{\epsilon})$

# Réseau de neurones convolutifs

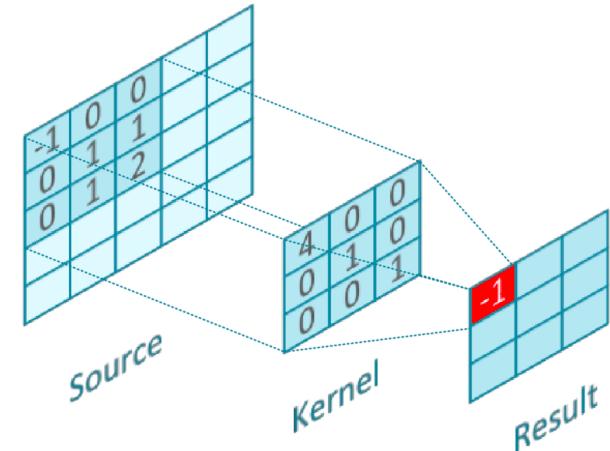
La convolution entre  $K \in \mathbb{R}^{d \times d \times c}$

et  $X \in \mathbb{R}^{D \times D \times c}$  est

$$(K * X)_{i,j \in [D]} =$$

$$\sum_{i',j' \in [d], k \in [c]} K_{i',j',k} \cdot X_{i-i'+1, j-j'+1, k},$$

où  $X$  est complété par des zéros..



Un RNC simple  $N : [0, 1]^{D \times D \times c_0} \rightarrow \mathbb{R}^{D \times D \times c_\ell}$  est

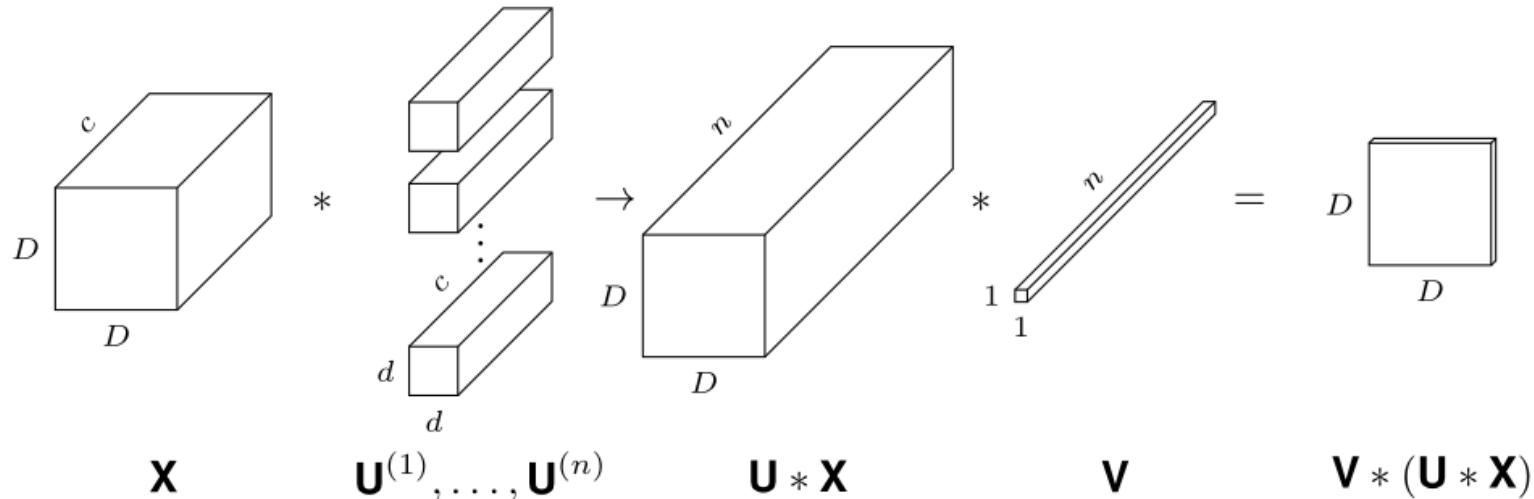
$$N(X) = \sigma \left( K^{(\ell)} * \sigma \left( K^{(\ell-1)} * \sigma \left( \dots * \sigma \left( K^{(1)} * X \right) \right) \right) \right)$$

où  $K^{(i)} \in \mathbb{R}^{d_i \times d_i \times c_{i-1} \times c_i}$ .

# Extension aux réseaux de neurones convolutifs

**Théorème (da Cunha et al., ICLR 2022).**

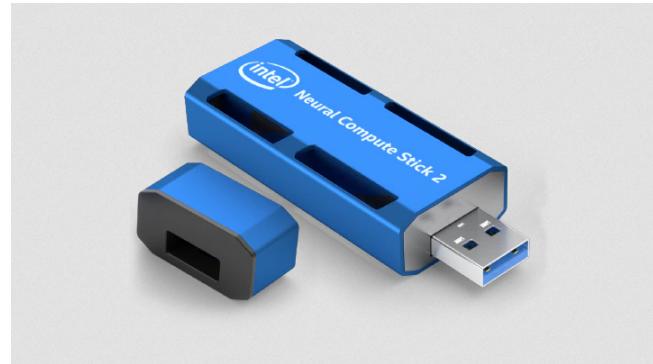
Étant donné  $\epsilon, \delta > 0$ , tout RNC avec  $k$  paramètres et  $\ell$  couches, et avec des noyaux de norme au plus constant, peut être approximé avec une erreur de  $\epsilon$  en élaguant un RNC aléatoire avec  $O(k \log \frac{k\ell}{\min\{\epsilon, \delta\}})$  paramètres et  $2\ell$  couches avec une probabilité d'au moins  $1 - \delta$ .



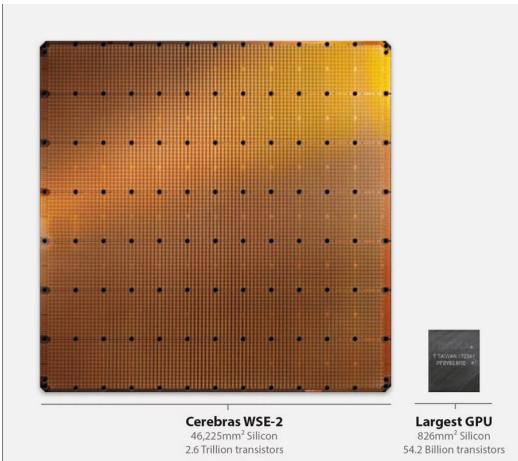
# Réduire la consommation énergétique : supports dédiés



IBM's Artificial Intelligence Unit



Intel® Neural Compute Stick 2



Cerebras' Wafer-Scale Engine



Mythic's MM1076 M.2 M Key Card

# Confier les calculs à la physique

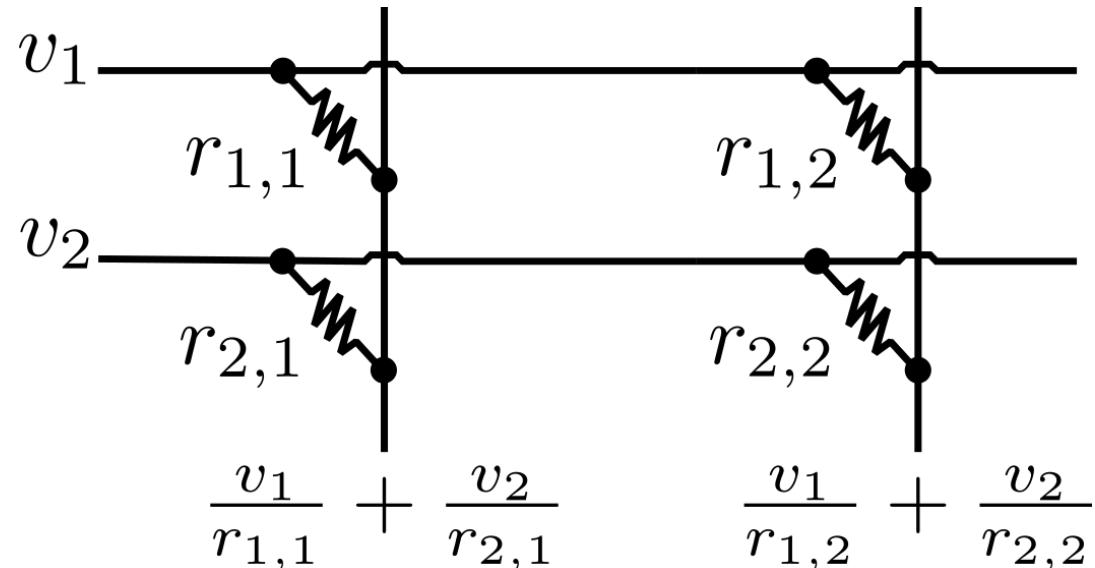
## Loi d'Ohm

$$V_{in} \xrightarrow[R]{\text{---}} I_{out} = \frac{V_{in}}{R}$$

Pour multiplier  $w$  et  $x$ , régler  $V_{in} = x$  et  $R = \frac{1}{w}$ , puis  $I_{out} = wx$ .

# Dispositif à barres résistives

MVM analogique  
via des barres  
transversales de  
résistances  
programmables.



Cfr. ~10k FLOPS pour un MVM numérique 100x100

**Problème** : il est difficile de fabriquer des **résistances programmables précises**.

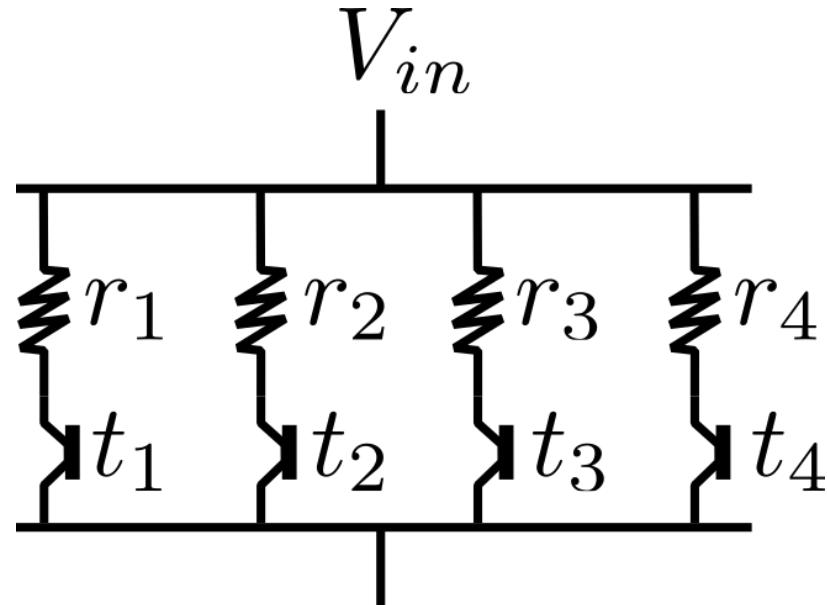
# *"Résistance équivalente modulable à partir de résistances imprécises"*

INRIA Dépôt de brevet FR2210217

Exploiter le bruit pour  
augmenter la précision

Théorème  
du SSA  
↓

Résistance  
programmable



$$I_{out} = V_{in} \sum_i \frac{t_i}{r_i}$$

# Travaux à venir

Publication des 4 résultats :

- Élagage des filtres dans le RNC
- Algorithme de hachage sensible à la localité FlyHash
- Nouvelle preuve de SSA
- Nouvelle preuve du SSA multidimensionnel

Terminer le développement de la première version du logiciel d'élagage

## Remerciements

INRIA : F. Segond, A. Schoofs, administration...

Collaborateurs: F. d'Amore, P. Crescenzi, I. Nachum...

DGA : R. Sol, R. Moha.